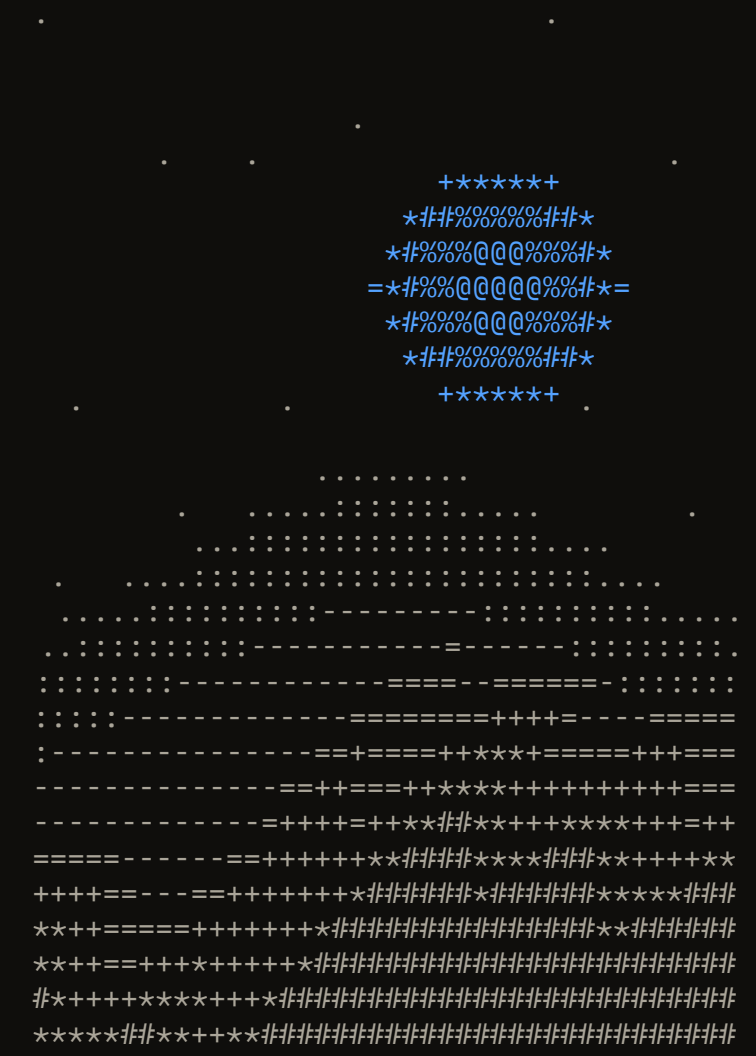
[进展汇报 · 第 07 期]

长文档 OCR 中的稀疏注意力

Sparse Attention for Long-Document OCR · 本周训练与评测进展



汇报人	张三
导师	李四 教授
单位	ABC institution
周期	2026.10.09 → 10.16

[00] AGENDA

本周概览

[01] 本周小结 p.03
[02] 实验 p.04
[03] 结果 p.06
[04] 问题与讨论 p.08
[05] 下周计划 p.09

[01] 本周小结

稀疏注意力在精度不降的前提下，显存减少 3.1 倍

[x]	在 FlashAttention-2 内核中重新实现块稀疏掩码	完成 · 10.12
[x]	完成 DocVQA-long 在 4k / 8k / 16k 上下文的完整评测	完成 · 10.14
[~]	消融实验：全局 token 数量（8 → 64）	3 / 5 组
[!]	32k 上下文下 batch size > 1 时显存溢出	受阻
[ ]	为 workshop 论文撰写相关工作一节	下周

02

[SECTION 02 / 05]

实验

长篇扫描文档上的稀疏注意力与稠密注意力对比 —— 实验设置、运行情况与遇到的问题。

[02] 方法

块稀疏注意力：局部窗口 + 少量全局 token

- 每个 64-token 的块只关注自身及左右相邻的 2 个块
- 16 个全局 token（版面锚点）可以看到所有块
- 掩码按页构建一次，在各层之间复用
- 可直接替换稠密 ViT 编码器，解码器无需重新训练

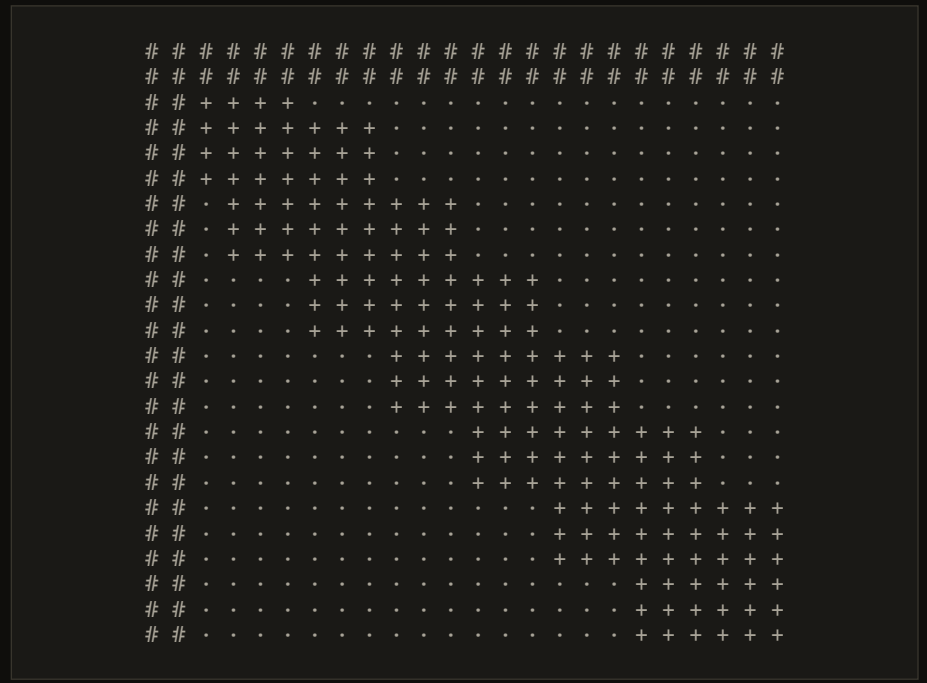


fig.01 — 注意力掩码（# 全局，+ 局部，· 跳过）

[03] 结果

精度持平，显存只需三分之一

+0.4 ↑
ANLS 相比稠密基线

3.1× ↓
16k 下显存节省

1.8× ↑
推理加速

模型	上下文	ANLS	显存（GB）	TOK/S
稠密 ViT-L（基线）	16k	71.2	38.4	412
Longformer 式	16k	69.8	15.1	690
块稀疏（本文）	**16k**	**71.6**	**12.3**	**745**

[04] 实现

整个掩码只需十行 PyTorch

sparse_mask.py | train.py

```python
def build_mask(n_blocks, window=1, n_global=16):
    """块稀疏掩码：局部窗口 + 全局 token。"""
    idx = torch.arange(n_blocks)
    dist = (idx[:, None] - idx[None, :]).abs()
    local = dist <= window

    glob = torch.zeros_like(local)
    glob[:n_global, :] = True
    glob[:, :n_global] = True
    return local | glob
```

→ L4–5
宽度为 1 的带状区域 → 相邻 3 个块

→ L7–9
全局行与列；锚点为前 16 个版面 token

→ L10
布尔或运算，直接送入 FlashAttention 的块掩码

[04] 问题与讨论

有两件事想听听您的意见

[!] BLOCKER

32k 上下文在 batch > 1 时显存溢出

目前解码器的激活显存占主导。梯度检查点有效，但吞吐下降约 35%。

[?] QUESTION

投稿目标选哪个会议?

结果已够 workshop 水平。ICDAR'27（截稿 01.15）是否现实，还是等完整消融再投?

[i] NOTE

集群配额 10.20 重置

已排队 3 组消融实验，周一开跑，预计周三完成。

→ 需要决定 投稿会议，请在 10.23（周四）前确定 —— 以便规划消融实验预算

[05] 下周计划

W43 计划：完成消融，开始写作

TODO (2)

- 撰写相关工作
  写作 · 2 天
- 用新分词器重跑基线
  实验 · 4 小时

DOING (2)

- 全局 token 消融（8→64）
  3 / 5 组
- 分块解码器修复 32k 溢出
  调试

DONE (2)

- 稀疏内核 + 单元测试
  已合并 #41
- DocVQA-long 4k/8k/16k 评测
  已记录

[EOF]

谢谢。

提问 · 意见 · 建议 → Q&A

